1 Метрики ML: классификация и регрессия

01 Матрица ошибок

Классификация выбирает категорию; **регрессия** предсказывает число с осмысленным размером ошибки. Score срочности ещё не делает классификатор регрессией. Сначала задайте positive: здесь это срочная заявка.

Строки - **actual**, столбцы - **predicted**, положительный класс первый:

Actual ↓ / Predicted →	Срочная	Обычная
Срочная	TP = 8	FN = 2
Обычная	FP = 4	TN = 86

TP - нашли срочную; FP - ложная тревога; FN - пропустили срочную; TN - верно оставили обычную. Всего 100, настоящих срочных 10, тревог 12. Проверяйте подписи осей, а не положение букв.

02 Accuracy, Precision, Recall и F1

Метрика	Формула	Пример	Вопрос
Accuracy	(TP + TN) / N	94%	Как часто правы вообще?
Precision	TP / (TP + FP)	66,7%	Сколько тревог настоящие?
Recall	TP / (TP + FN)	80%	Сколько срочных нашли?
F1	2PR / (P + R)	72,7%	Каков их баланс?

F1 = 2TP / (2TP + FP + FN) - гармоническое среднее: слабую составляющую трудно скрыть сильной. F1 не учитывает TN и цену ошибок. При редком классе «всегда обычная» даёт высокий Accuracy и нулевой Recall. Нулевой знаменатель требует явного соглашения.

03 Порог и цена ошибки

Правило: **positive, если score ⩾ t**. Score не обязательно калиброванная вероятность. На фиксированных scores снижение порога расширяет положительные предсказания: TP и FP не убывают, FN уменьшается или остаётся прежним. Recall не убывает; Precision может меняться в обе стороны.

Цена = FP × цена ложной тревоги + FN × цена пропуска. При ценах 1 и 20 наш ущерб: 4 + 40 = 44. Порог выбирают по цене или ограничению, например Recall ⩾ 90%, на **validation**; **test** оставляют для финальной оценки.

04 ROC и ROC-AUC

ROC перебирает пороги: **ось X - FPR = FP / (FP + TN)**, **ось Y - TPR = Recall**. Здесь точка (4/90; 8/10) ≈ (0,044; 0,8). Хорошее ранжирование ведёт к левому верхнему углу; диагональ - случайное ранжирование.

ROC-AUC - вероятность, что случайный positive получит score выше случайного negative, с **половиной зачёта за равенство**. **AUC = 0,5 - случайное ранжирование в ожидании; 1 - идеальное.** AUC = 0,8 не означает Accuracy 80%. AUC оценивает ранжирование, а не выбранный порог, калибровку или цену ошибок. При редком классе дополнительно смотрите PR.



05 Precision-Recall и Average Precision

PR: **X - Recall, Y - Precision**. Показывает, сколько найдено positive и насколько чиста очередь тревог. При редком классе даже маленький FPR может дать много FP из огромного числа negative. Ориентир Precision случайного ранжирования - **prevalence**, доля positive; сравнивать наборы с разными долями нужно осторожно.

AP = Σ (Recall$_i$ − Recall$_{i-1}$) × Precision$_i$. Это сумма precision с весами приростов recall. **AP не равна в общем случае PR-AUC по трапециям**: способ интерполяции различается. В отчёте называйте метод, класс и выборку.

06 Micro, macro и weighted

Для нескольких классов сначала считайте каждый как «этот класс против остальных».

Усреднение	Как считать	Что важно
Micro	Сложить TP, FP, FN, затем метрику	Больше вес частых классов
Macro	Среднее per-class метрик поровну	Видны редкие классы
Weighted	Среднее с весами support	Support - число истинных объектов класса

Macro-F1 - среднее **F1 классов**, а не F1 от средних P и R. Только при **одной метке на объект и учёте всех классов** micro-P = micro-R = micro-F1 = Accuracy. На multilabel и подмножестве классов это переносить нельзя.

07 MAE, MSE и RMSE

Для регрессии ошибка $e_i = \hat{y}_i - y_i$ (прогноз − факт); n - число объектов.

Метрика	Формула	Смысл
MAE	Σ abs(e_i) / n	Средний абсолютный промах
MSE	Σ e_i^2 / n	Крупные промахи усиливает квадрат
RMSE	√MSE	Та же единица, что у цели

Для y = [10, 20, 30], ŷ = [12, 18, 40]: **MAE = 14/3 ≈ 4,67; MSE = 36; RMSE = 6**. MSE измеряется в квадрате единицы цели. Удвоение одного промаха учетверяет его вклад в сумму квадратов, но не всю RMSE.

08 R^2 и базовый прогноз

$R^2 = 1 - SSE / SST$, где $SSE = \Sigma(y_i - \hat{y}_i)^2$, $SST = \Sigma(y_i - \bar{y})^2$, а $\bar{y}$ - среднее истинной цели на оцениваемом наборе.

Для нашего примера $\bar{y}$ = 20, SSE = 108, SST = 200: **R^2 = 0,46**. Единица - идеальные прогнозы; ноль - ошибка как у постоянного среднего этого набора; **$R^2 < 0$ допустима**: хуже такой базы. Это не Accuracy и не доля угаданных чисел. При постоянной цели SST = 0: формула не определена, библиотека может подставлять значения по соглашению. Практический baseline для теста обучают только на train.

09 Как выбрать метрику

Начните с цели и цены ошибки: ложные тревоги → Precision; пропуски → Recall; баланс → F1; редкие события → PR/AP вместе с числом FP. Ранжирование → ROC-AUC; крупные числовые промахи → RMSE, обычный размер ошибки → MAE. R^2 дополняйте ошибкой в единицах задачи и baseline.

Ответ ментору: тип задачи → positive и ошибки → знаменатель метрики → ограничение → числовой пример. В наборе из 99 обычных и 1 срочной заявки высокий Accuracy ещё не означает пользу. Ошибка 2 → 20 увеличивает вклад в MSE в 100 раз, в MAE - в 10 раз. Модель и порог подбирайте на validation, затем проверяйте на отложенном test без утечки.