Метрики ML: смысл, формулы и расчёт

01 Матрица ошибок

Классификация выбирает категорию; **регрессия** предсказывает число с осмысленным размером ошибки. Score срочности ещё не делает классификатор регрессией. Сначала задайте positive: здесь это срочная заявка.

Строки - **actual**, столбцы - **predicted**, положительный класс первый:

Actual ↓ / Predicted →	Срочная	Обычная
Срочная	TP = 8	FN = 2
Обычная	FP = 4	TN = 86

TP - нашли срочную; FP - ложная тревога; FN - пропустили срочную; TN - верно оставили обычную. Всего 100, настоящих срочных 10, тревог 12. Проверяйте подписи осей, а не положение букв.

02 Accuracy, Precision, Recall и F1

N - всего заявок; P - precision; R - recall. Все четыре метрики: **больше - лучше, 1 = 100%** (но полезность зависит от цены ошибок).

Метрика	Формула	Пример	Вопрос
Accuracy	(TP + TN) / N	94%	Как часто правы вообще?
Precision	TP / (TP + FP)	66,7%	Сколько тревог настоящие?
Recall	TP / (TP + FN)	80%	Сколько срочных нашли?
F1	2PR / (P + R)	72,7%	Каков их баланс?

F1 = 2TP / (2TP + FP + FN) - гармоническое среднее: слабую составляющую трудно скрыть сильной. F1 не учитывает TN и цену ошибок. При редком классе «всегда обычная» даёт высокий Accuracy и нулевой Recall. Нулевой знаменатель требует явного соглашения.

03 Порог и цена ошибки

Правило: **positive, если score ⩾ t**. Score не обязательно калиброванная вероятность. На фиксированных scores снижение порога расширяет положительные предсказания: TP и FP не убывают, FN уменьшается или остаётся прежним. Recall не убывает; Precision может меняться в обе стороны.

Цена = FP × цена ложной тревоги + FN × цена пропуска. При ценах 1 и 20 наш ущерб: 4 + 40 = 44. Порог выбирают по цене или ограничению, например Recall ⩾ 90%, на **validation**; **test** оставляют для финальной оценки.

Как посчитать нагрузку. Из 1 000 заявок 20 срочных, значит обычных 1 000 - 20 = 980. Пусть TPR = 0,8, FPR = 0,05. TPR умножаем на срочные, FPR - на обычные.

TP = 20 × 0,8 = 16; FN = 20 - 16 = 4. FP = 980 × 0,05 = 49; TN = 980 - 49 = 931. Очередь = TP + FP = 65 уведомлений. Precision = 16/65 ≈ 24,6%. Требование «recall ⩾ 0,8 и не более 50 уведомлений» не выполнено: полнота подходит, бюджет превышен. Всегда проверяйте оба условия.

Метрики ML: смысл, формулы и расчёт

04 ROC и ROC-AUC

ROC показывает компромисс между найденными срочными и ложными тревогами при разных порогах. **AUC** расшифровывается как «площадь под кривой»; ROC-AUC - площадь именно под ROC. Чем больше, тем лучше ранжирование.

ROC перебирает пороги: **ось X - FPR = FP / (FP + TN)**, **ось Y - TPR = Recall**. Здесь точка (4/90; 8/10) ≈ (0,044; 0,8). Хорошее ранжирование ведёт к левому верхнему углу; диагональ - случайное ранжирование.

ROC-AUC - вероятность, что случайный positive получит score выше случайного negative, с **половиной зачёта за равенство**. **AUC = 0,5 - случайное ранжирование в ожидании; 1 - идеальное.** AUC = 0,8 не означает Accuracy 80%. AUC оценивает ранжирование, а не выбранный порог, калибровку или цену ошибок. При редком классе дополнительно смотрите PR.

Как посчитать руками. Пусть scores по убыванию: [0,9; 0,8; 0,7; 0,1], классы: [срочная A, обычная B, срочная C, обычная D]. Две срочные и две обычные дают 2 × 2 = 4 пары. A выше B и D: 2 зачёта. C выше D, но ниже B: 1 зачёт. **ROC-AUC = (2 + 1) / 4 = 0,75.** При равных scores добавьте 0,5 за пару; делите на число всех пар.

Точки (FPR; TPR): (0; 0) → (0; 0,5) → (0,5; 0,5) → (0,5; 1) → (1; 1). Площадь: 0,5 × 0,5 + 0,5 × 1 = 0,75. Срочная даёт шаг вверх, обычная - вправо. Для ROC нужны оба истинных класса; без одного из них ROC-AUC не определена.

05 Precision-Recall и Average Precision

PR: **X - Recall, Y - Precision**. Показывает, сколько найдено positive и насколько чиста очередь тревог. При редком классе даже маленький FPR может дать много FP из огромного числа negative. Ориентир Precision случайного ранжирования - **prevalence**, доля positive; сравнивать наборы с разными долями нужно осторожно.

AP = Σ (Recall$_i$ − Recall$_{i-1}$) × Precision$_i$. Это сумма precision с весами приростов recall. **AP не равна в общем случае PR-AUC по трапециям**: способ интерполяции различается. В отчёте называйте метод, класс и выборку.

Как посчитать AP руками. В порядке A, B, C, D из примера выше:

Добавили	Recall	Precision
A, срочная	1/2	1/1
B, обычная	1/2	1/2
C, срочная	2/2	2/3
D, обычная	2/2	2/4

Recall растёт на 1/2 при каждой срочной. **AP = 1/2 × 1 + 0 × 1/2 + 1/2 × 2/3 + 0 × 1/2 = 5/6 ≈ 0,833.** При разных scores это среднее precision в моментах нахождения срочных: (1 + 2/3) / 2. Обычные ухудшают precision последующих находок.

Чем выше AP, тем лучше; 1 - идеально, 0,833 не означает «83,3% правильных ответов». Равные scores включайте одной группой и используйте общую формулу с приростом recall; искусственный порядок внутри группы меняет ответ.

Трапеции: площадь участка = ширина по recall × среднее двух precision. С условной начальной точкой (0; 1) в этом примере: 0,5 × (1 + 1)/2 + 0,5 × (1/2 + 2/3)/2 = 19/24 ≈ 0,792. Вертикальные участки имеют нулевую ширину. AP и трапеции дают разные числа из-за способа подсчёта площади.

06 Micro, macro и weighted

Где применяют. В бинарной классификации два класса (спам / не спам); в многоклассовой - три и больше (кошка / собака / птица). Усреднение применимо в обоих случаях: каждый класс рассматривают как «этот класс против остальных». В многометочной задаче у объекта несколько меток - усреднять тоже можно.

Когда усреднение не нужно. В бинарной задаче часто важен один positive, например спам: считают его Precision, Recall и F1 отдельно, без усреднения с «не спамом».

Пусть $F1_i$ - F1 класса i, n_i - число его настоящих объектов (**support**), K - число классов, N - сумма n_i. **Σ означает «сложить по всем классам».**

Способ	Формула для F1	Когда выбирать
Macro	$\Sigma F1_i / K$	Каждый класс одинаково важен, включая редкий
Weighted	$\Sigma (n_i \times F1_i) / N$	Нужно учесть реальную частоту классов; редкий может скрыться
Micro	$2\Sigma TP / (2\Sigma TP + \Sigma FP + \Sigma FN)$	Нужен общий итог по решениям; сначала складываем счётчики

Пример. Из 6 кошек все найдены; из 4 собак две названы кошками. Для кошек TP=6, FP=2, FN=0; F1=12/14≈0,857. Для собак TP=2, FP=0, FN=2; F1=4/6≈0,667.

Macro = (0,857 + 0,667)/2 ≈ **76,2%**. Weighted = (6 × 0,857 + 4 × 0,667)/10 ≈ **78,1%**. Micro: сумма TP=8, FP=2, FN=2; 16/(16+2+2) = **80%**.

Запомнить: macro - классы поровну; weighted - по численности; micro - общие счётчики. Macro-F1 усредняет готовые F1, а не средние P и R. Только при **одной метке на объект и учёте всех классов** micro-P = micro-R = micro-F1 = Accuracy. Для нескольких меток или части классов равенство не гарантируется.

Метрики ML: смысл, формулы и расчёт

07 MAE, MSE и RMSE

Регрессия предсказывает число, например время в минутах. **Размер промаха** - разница между прогнозом и фактом без минуса. Например, прогноз 18, факт 20: промах 2 минуты. Прогноз 22 при факте 20 - тоже промах 2 минуты.

MAE = сумма размеров промахов / число заявок. Показывает, на сколько минут в среднем промахнулись. Складываем все промахи без минуса и делим на число заявок.

MSE = сумма квадратов промахов / число заявок. Каждый промах сначала возводим в квадрат, потом складываем и делим на число заявок. Большие промахи влияют сильнее. Единицы - минуты².

RMSE = √MSE. Берём квадратный корень из MSE, чтобы результат снова был в минутах. Большие промахи по-прежнему влияют сильнее.

Для всех трёх **меньше - лучше; 0 - идеально**. Разницу со знаком просто усреднять нельзя: +2 и -2 дадут 0, хотя в обоих случаях прогноз неточен.

Пример по шагам: факт [10, 20, 30], прогноз [12, 18, 40]. Всего 3 заявки.

Факт	Прогноз	Размер промаха	Квадрат промаха
10	12	2	$2^2 = 4$
20	18	2	$2^2 = 4$
30	40	10	$10^2 = 100$

MAE = (2 + 2 + 10) / 3 = 14/3 ≈ 4,67 мин. Складываем размеры промахов и делим на 3.

MSE = (2^2 + 2^2 + 10^2) / 3 = (4 + 4 + 100) / 3 = 36 мин². Складываем квадраты промахов и делим на 3.

RMSE = √36 = 6 мин. Извлекаем корень из полученного MSE.

Если один промах вырос с 2 до 20, его размер вырос в 10 раз, а квадрат - с 4 до 400, в 100 раз. Это изменение одного слагаемого, а не множитель всей метрики: остальные промахи тоже участвуют в расчёте. При одинаковых данных и весах RMSE ⩾ MAE.

Эти метрики одинаково оценивают промах на 2 минуты вверх и вниз. Если недооценка дороже переоценки, отдельно проверяйте направление ошибок.

08 R^2 и базовый прогноз

R^2 сравнивает модель с прогнозом «всем среднее» по квадратам промахов. Больше - лучше: 1 - идеально; 0 - как среднее; ниже 0 - хуже. Это не доля верных прогнозов и не минуты.

R^2 = 1 - (сумма квадратов промахов модели / сумма квадратов промахов прогноза средним). Для краткости первую сумму называют SSE, вторую - SST.

Среднее фактов = сумма фактических значений / число заявок. Базовый прогноз выдаёт всем это среднее.

Шаг 1. Среднее фактов: (10 + 20 + 30) / 3 = 20. Базовый прогноз: [20, 20, 20].

Шаг 2. С чем сравниваем? Ошибки простого способа: 20 - 10 = 10; 20 - 20 = 0; 20 - 30 = -10. Их квадраты: 100, 0, 100. **SST = 100 + 0 + 100 = 200.**

Шаг 3. Ошибки модели. Для прогноза [12, 18, 40] выше получены квадраты 4, 4, 100. **SSE = 4 + 4 + 100 = 108.** В формуле сравниваются суммы, без деления на число заявок.

Шаг 4. Подстановка: R^2 = 1 - 108/200 = 0,46. Было 200 у простого способа, стало 108 у модели. Сумма квадратов уменьшилась на (200 - 108)/200 = 46%, а не «46% прогнозов верны».

Как сравнить два прогноза: оставьте факты [10, 20, 30], замените прогноз на [8, 20, 32]. Ошибки [-2, 0, 2]; модули [2, 0, 2]; квадраты [4, 0, 4].

Метрика	[12, 18, 40]	[8, 20, 32]
MAE	14/3 ≈ 4,67	4/3 ≈ 1,33
MSE	108/3 = 36	8/3 ≈ 2,67
RMSE	6	√(8/3) ≈ 1,63
R^2	1 - 108/200 = 0,46	1 - 8/200 = 0,96

Второй прогноз лучше по всем четырём метрикам. **SST осталось 200**, потому что реальные значения не менялись. R^2 разных наборов напрямую не сравнивайте: меняется разброс фактов и знаменатель.

При постоянной цели SST = 0, обычная формула не определена; библиотечная подстановка - отдельное соглашение. Среднее оцениваемых фактов нужно для расчёта R^2. Реальный прогноз для новых заявок строят по train, без знания будущих ответов.

09 Как выбрать метрику

Начните с цели и цены ошибки: ложные тревоги → Precision; пропуски → Recall; баланс → F1; редкие события → PR/AP вместе с числом FP. Ранжирование → ROC-AUC; крупные числовые промахи → RMSE, обычный размер ошибки → MAE. R^2 дополняйте ошибкой в единицах задачи и baseline.

Ответ ментору: тип задачи → positive и ошибки → знаменатель метрики → ограничение → числовой пример. В наборе из 99 обычных и 1 срочной заявки высокий Accuracy ещё не означает пользу. Ошибка 2 → 20 увеличивает вклад в MSE в 100 раз, в MAE - в 10 раз. Модель и порог подбирайте на validation, затем проверяйте на отложенном test без утечки.