Метрики ML: смысл, формулы и расчёт

01 Матрица ошибок

Классификация выбирает категорию; **регрессия** предсказывает число с размером ошибки. Macro/micro/weighted F1 - про классы; MAE/MSE/RMSE/R^2 - про числовые прогнозы. Score срочности ещё не делает классификатор регрессией.

Строки - **Fact (факт)**, столбцы - **Pred (предсказание модели)**. Positive (класс 1) - срочная заявка:

Fact / Pred	Срочная: Pred = 1	Обычная: Pred = 0
Срочная	TP = 8	FN = 2
Обычная	FP = 4	TN = 86

TP - нашли срочную; FP - обычную ошибочно назвали срочной; FN - срочную пропустили; TN - обычную верно оставили обычной.

Проверка: TP + FP + FN + TN = 100 заявок. Настоящих срочных: TP + FN = 10. Обычных: FP + TN = 90. Поэтому **TN = 90 - FP = 86**, а не количество пропущенных срочных.

Fact не меняется при выборе порога. Меняется Pred: кого модель назовёт срочным. Проверяйте подписи осей: в другой таблице их могут поменять местами.

02 Accuracy, Precision, Recall и F1

N - всего заявок; P - precision; R - recall. Все четыре метрики: **больше - лучше, 1 = 100%** (но полезность зависит от цены ошибок).

Метрика	Формула	Пример	Вопрос
Accuracy	(TP + TN) / N	94%	Как часто правы вообще?
Precision	TP / (TP + FP)	8/12 ≈ 66,7%	Доверять тревогам?
Recall	TP / (TP + FN)	8/10 = 80%	Сколько срочных нашли?
F1	2PR / (P + R)	72,7%	Каков их баланс?

Precision: среди названных срочными сколько настоящих? Берём **столбец Pred = 1**, включая FP. **Recall:** среди всех настоящих срочных сколько нашли? Берём **строку Fact = 1**, включая FN. Precision = 100% означает FP = 0; Recall = 100% означает FN = 0, если знаменатели ненулевые.

F1 = 2TP / (2TP + FP + FN) - гармоническое среднее: слабую составляющую трудно скрыть сильной. F1 не учитывает TN и цену ошибок. При редком классе «всегда обычная» даёт высокий Accuracy и нулевой Recall. Нулевой знаменатель требует явного соглашения.

03 Порог и цена ошибки

Правило: **positive, если score ⩾ t**. Score не обязательно калиброванная вероятность. На фиксированных scores снижение порога расширяет положительные предсказания: TP и FP не убывают, FN уменьшается или остаётся прежним. Recall не убывает; Precision может меняться в обе стороны.

Порог и ранжирование - разные вещи. При прежних scores смена t меняет TP/FP/FN/TN и Precision/Recall, но **не ROC-AUC и AP**: выбираем другую точку на прежних кривых. Срочная со score 0,8 выше обычной с 0,2; при t=0,9 обе будут обычными, при t=0,5 срочную найдём. Порядок верный в обоих случаях.

Цена = FP × цена ложной тревоги + FN × цена пропуска. При ценах 1 и 20 наш ущерб: 4 + 40 = 44. Порог выбирают по цене или ограничению, например Recall ⩾ 90%, на **validation**; **test** оставляют для финальной оценки.

Как посчитать нагрузку. Из 1 000 заявок 20 срочных, значит обычных 1 000 - 20 = 980. Пусть TPR = 0,8, FPR = 0,05. TPR умножаем на срочные, FPR - на обычные.

TP = 20 × 0,8 = 16; FN = 20 - 16 = 4. FP = 980 × 0,05 = 49; TN = 980 - 49 = 931. Очередь = TP + FP = 65 уведомлений. Precision = 16/65 ≈ 24,6%. Требование «recall ⩾ 0,8 и не более 50 уведомлений» не выполнено: полнота подходит, бюджет превышен. Всегда проверяйте оба условия.

AP: простой пример перед PR-кривой (§05). Оценивает, насколько рано находим настоящие positive в списке по убыванию score. Без одинаковых scores: складываем Precision при каждой находке positive и делим на число всех настоящих positive.

Простой пример: срочная → обычная → обычная → срочная. Находки на местах 1 и 4: Precision = 1/1 и 2/4. **AP = (1 + 0,5)/2 = 0,75.** Обычные учитываются в знаменателе следующей находки. Каждая находка даёт прирост Recall = 1/2, поэтому общая формула даёт то же: (1/2)×1 + (1/2)×0,5 = 0,75.

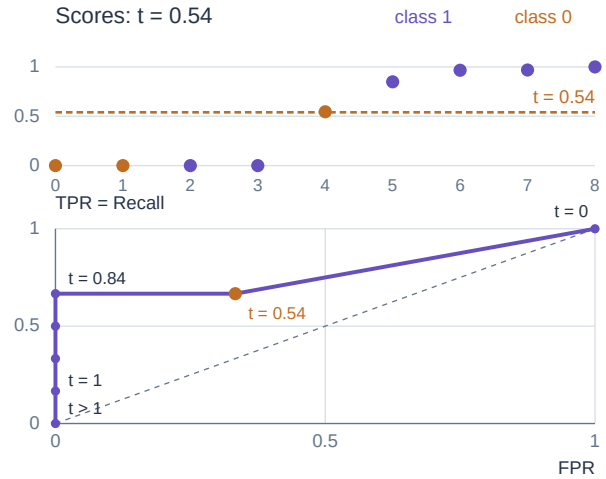
ROC-AUC сравнивает пары; AP учитывает Precision при находках. При редком positive высокая ROC-AUC не гарантирует мало ложных тревог: смотрите PR/AP.

Метрики ML: смысл, формулы и расчёт

04 ROC и ROC-AUC

Меняем порог t, а не scores. Если score ⩾ t, предсказываем 1. Одна точка - один порог; левее и выше лучше.

Пример из видео: 9 объектов - 6 срочных, 3 обычных. Scores и классы показаны на графике; правило score ⩾ t.



X = FPR = FP/3; Y = TPR = Recall = TP/6. Делим FP на 3 настоящих negative, TP - на 6 настоящих positive.

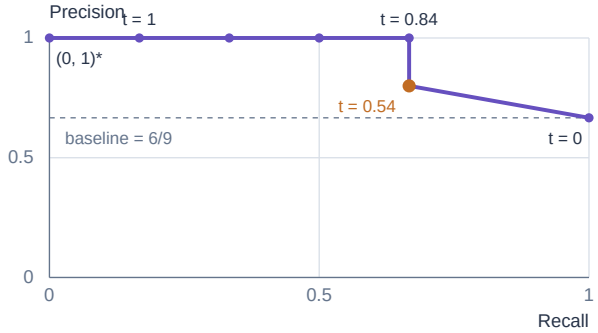
t	TP	FP	FPR	TPR
> 1	0	0	0	0
1	1	0	0	1/6
0,84	4	0	0	4/6
0,54	4	1	1/3	4/6
0	6	3	1	1

t=0,54: TP=4, FP=1, FN=2, TN=2; точка (1/3; 4/6). Нулевые scores включаем вместе при t=0. На кривой - все уникальные scores, в таблице - выбранные пороги.

ROC-AUC - площадь под ROC; тоже можно считать трапециями. Здесь (12 побед + 4 равенства × 0,5)/18 пар = **7/9 ≈ 0,778**. Сравниваем score срочной и обычной: 1 - идеальный порядок, 0,5 - случайный в ожидании. Не Accuracy; нужны оба класса.

05 Precision-Recall и Average Precision

Те же данные, те же пороги; другие оси. X = Recall = TP/(TP+FN); Y = Precision = TP/(TP+FP). Recall - какую долю класса 1 нашли; Precision - какая доля наших тревог верна.



* (Recall=0; Precision=1)

t	Recall	Precision
> 1	0	Не определена*
1	1/6	1/1
0,84	4/6	4/4
0,54	4/6	4/5
0	6/6	6/9

t=0,54: точка (Recall; Precision) = (2/3; 0,8). При t=0: Recall=1, Precision=2/3 - нашли всех, но треть тревог ложная.

***Без тревог Precision не определена:** знаменатель 0. Точка (Recall=0; Precision=1) добавлена только для начала графика, а не как оценка качества.

Общая формула: AP = Σ (Recall$_i$ - Recall$_{i-1}$) × Precision$_i$. Σ - сложить шаги; умножаем прирост Recall на Precision после шага. Равные scores включаем группой. Для девяти объектов выше: **AP = (4/6)×1 + (2/6)×(6/9) = 8/9 ≈ 0,889**.

PR-AUC по трапециям: ширина по Recall × средняя высота Precision; вертикали дают 0. Здесь **41/45 ≈ 0,911**, а AP ≈ 0,889: разные способы расчёта. Указывайте метод; это не процент верных ответов.

Пунктир - доля positive: 6/9. Сравнивайте PR/AP на одних данных: доля классов влияет на оценку.

06 Micro, macro и weighted

Где применяют. В бинарной классификации два класса (спам / не спам); в многоклассовой - три и больше (кошка / собака / птица). Усреднение применимо в обоих случаях: каждый класс рассматривают как «этот класс против остальных». В многометочной задаче у объекта несколько меток - усреднять тоже можно.

Когда усреднение не нужно. В бинарной задаче часто важен один positive, например спам: считают его Precision, Recall и F1 отдельно, без усреднения с «не спамом».

Пусть $F1_i$ - F1 класса i, n_i - число его настоящих объектов (**support**), K - число классов, N - сумма n_i. **Σ означает «сложить по всем классам».**

Способ	Формула для F1	Когда выбирать
Macro	Σ $F1_i$ / K	Каждый класс одинаково важен, включая редкий
Weighted	Σ (n_i × $F1_i$) / N	Нужно учесть реальную частоту классов; редкий может скрыться
Micro	2ΣTP / (2ΣTP + ΣFP + ΣFN)	Нужен общий итог по решениям; сначала складываем счётчики

Пример. Из 6 кошек все найдены; из 4 собак две названы кошками. Для кошек TP=6, FP=2, FN=0; F1=12/14≈0,857. Для собак TP=2, FP=0, FN=2; F1=4/6≈0,667.

Macro = (0,857 + 0,667)/2 ≈ **76,2%**. Weighted = (6 × 0,857 + 4 × 0,667)/10 ≈ **78,1%**. Micro: сумма TP=8, FP=2, FN=2; 16/(16+2+2) = **80%**.

Запомнить: macro - классы поровну; weighted - по численности; micro - общие счётчики. Macro-F1 усредняет готовые F1, а не средние P и R. Только при **одной метке на объект и учёте всех классов** micro-P = micro-R = micro-F1 = Accuracy. Для нескольких меток или части классов равенство не гарантируется.

Метрики ML: смысл, формулы и расчёт

07 MAE, MSE и RMSE

Регрессия предсказывает число, например время в минутах. **Размер промаха** - разница между прогнозом и фактом без минуса. Например, прогноз 18, факт 20: промах 2 минуты. Прогноз 22 при факте 20 - тоже промах 2 минуты.

MAE = сумма размеров промахов / число заявок. Показывает, на сколько минут в среднем ошиблись по модулю.

MSE = сумма квадратов промахов / число заявок. Сначала квадрат каждой ошибки, затем среднее. Большие промахи влияют сильнее. Единицы - минуты².

RMSE = √MSE. Берём квадратный корень из MSE, чтобы результат снова был в минутах. Большие промахи по-прежнему влияют сильнее.

Для всех трёх **меньше - лучше; 0 - идеально**. Разницу со знаком просто усреднять нельзя: +2 и -2 дадут 0, хотя в обоих случаях прогноз неточен.

Пример по шагам: факт [10, 20, 30], прогноз [12, 18, 40]. Всего 3 заявки.

Факт	Прогноз	Размер промаха	Квадрат промаха
10	12	2	$2^2 = 4$
20	18	2	$2^2 = 4$
30	40	10	$10^2 = 100$

MAE = (2 + 2 + 10) / 3 = 14/3 ≈ 4,67 мин.

MSE = (2^2 + 2^2 + 10^2) / 3 = (4 + 4 + 100) / 3 = 36 мин².

RMSE = √36 = 6 мин.

Если один промах вырос с 2 до 20, его размер вырос в 10 раз, а квадрат - с 4 до 400, в 100 раз. Это изменение одного слагаемого, а не множитель всей метрики: остальные промахи тоже участвуют в расчёте. При одинаковых данных и весах RMSE ⩾ MAE.

Эти метрики одинаково оценивают промах на 2 минуты вверх и вниз. Если недооценка дороже переоценки, отдельно проверяйте направление ошибок.

08 R^2 и базовый прогноз

R^2 сравнивает модель с прогнозом «всем среднее» по квадратам промахов. 1 - идеально; **0 - не лучше прогноза средним**, ниже 0 - хуже. Это не доля верных прогнозов и не минуты.

R^2 = 1 - (сумма квадратов промахов модели / сумма квадратов промахов прогноза средним). Для краткости первую сумму называют SSE, вторую - SST.

Среднее фактов = сумма фактических значений / число заявок. Базовый прогноз выдаёт всем это среднее.

Шаг 1. Среднее фактов: (10 + 20 + 30) / 3 = 20. Базовый прогноз: [20, 20, 20].

Шаг 2. С чем сравниваем? Ошибки простого способа: 20 - 10 = 10; 20 - 20 = 0; 20 - 30 = -10. Их квадраты: 100, 0, 100. **SST = 100 + 0 + 100 = 200.**

Шаг 3. Ошибки модели. Для прогноза [12, 18, 40] выше получены квадраты 4, 4, 100. **SSE = 4 + 4 + 100 = 108.** В формуле сравниваются суммы, без деления на число заявок.

Шаг 4. Не забыть «1 -»: 108/200 = 0,54 - оставшаяся доля ошибки. **R^2 = 1 - 0,54 = 0,46** - сумма квадратов ошибок уменьшилась на 46% относительно среднего. Не «46% прогнозов верны».

R^2 = 0,8 не гарантирует приемлемую ошибку. Если MAE = 30 минут при допустимых средних 5, модель не подходит. R^2 - сравнение со средним; MAE/RMSE - размер ошибки. Для требования «ни один промах не больше 5» одного MAE недостаточно.

R^2 = -0,3: сумма квадратов ошибок на 30% больше, чем у прогноза средним. Отрицательной ошибки в минутах здесь нет. R^2 разных наборов напрямую не сравнивайте: меняется разброс фактов.

При постоянной цели SST = 0, обычная формула не определена; библиотечная подстановка - отдельное соглашение. Среднее оцениваемых фактов нужно для расчёта R^2. Реальный прогноз для новых заявок строят по train, без знания будущих ответов.

09 Как выбрать метрику

Сначала определите тип ответа модели.

Задача / требование	Что смотреть
Категория; доверять тревогам	Precision
Категория; меньше пропусков	Recall
Баланс Precision и Recall	F1; цену ошибок проверить отдельно
Каждый класс одинаково важен	Macro F1
F1 с учётом частоты классов	Weighted F1
Общие TP, FP и FN классов	Micro F1
Качество списка по score	ROC-AUC и PR/AP; не выбранный порог
Число; средний размер ошибки	MAE в рублях, минутах и т. п.
Число; большие ошибки особенно нежелательны	RMSE в исходных единицах; MSE в квадратных
Число; лучше ли прогноза средним	R^2 вместе с MAE/RMSE

Сначала ограничения, потом лучший результат. Если команда проверяет максимум 50 тревог, вариант с 100 не подходит даже при лучшем Recall. Выберите максимальный Recall среди допустимых порогов.

Ответ ментору: тип задачи → positive и ошибки → знаменатель метрики → ограничение → числовой пример. В наборе из 99 обычных и 1 срочной заявки высокий Accuracy ещё не означает пользу. Ошибка 2 → 20 увеличивает вклад в MSE в 100 раз, в MAE - в 10 раз. Модель и порог подбирайте на validation, затем проверяйте на отложенном test без утечки.