Метрики ML: смысл, формулы и расчёт

01 Матрица ошибок

Классификация выбирает категорию; **регрессия** предсказывает число с осмысленным размером ошибки. Score срочности ещё не делает классификатор регрессией. Сначала задайте positive: здесь это срочная заявка.

Строки - **actual**, столбцы - **predicted**, положительный класс первый:

Actual ↓ / Predicted →	Срочная	Обычная
Срочная	TP = 8	FN = 2
Обычная	FP = 4	TN = 86

TP - нашли срочную; FP - ложная тревога; FN - пропустили срочную; TN - верно оставили обычную. Всего 100, настоящих срочных 10, тревог 12. Проверяйте подписи осей, а не положение букв.

02 Accuracy, Precision, Recall и F1

N - всего заявок; P - precision; R - recall. Все четыре метрики: **больше - лучше, 1 = 100%** (но полезность зависит от цены ошибок).

Метрика	Формула	Пример	Вопрос
Accuracy	(TP + TN) / N	94%	Как часто правы вообще?
Precision	TP / (TP + FP)	66,7%	Сколько тревог настоящие?
Recall	TP / (TP + FN)	80%	Сколько срочных нашли?
F1	2PR / (P + R)	72,7%	Каков их баланс?

F1 = 2TP / (2TP + FP + FN) - гармоническое среднее: слабую составляющую трудно скрыть сильной. F1 не учитывает TN и цену ошибок. При редком классе «всегда обычная» даёт высокий Accuracy и нулевой Recall. Нулевой знаменатель требует явного соглашения.

03 Порог и цена ошибки

Правило: **positive, если score ⩾ t**. Score не обязательно калиброванная вероятность. На фиксированных scores снижение порога расширяет положительные предсказания: TP и FP не убывают, FN уменьшается или остаётся прежним. Recall не убывает; Precision может меняться в обе стороны.

Цена = FP × цена ложной тревоги + FN × цена пропуска. При ценах 1 и 20 наш ущерб: 4 + 40 = 44. Порог выбирают по цене или ограничению, например Recall ⩾ 90%, на **validation**; **test** оставляют для финальной оценки.

Как посчитать нагрузку. Из 1 000 заявок 20 срочных, значит обычных 1 000 - 20 = 980. Пусть TPR = 0,8, FPR = 0,05. TPR умножаем на срочные, FPR - на обычные.

TP = 20 × 0,8 = 16; FN = 20 - 16 = 4. FP = 980 × 0,05 = 49; TN = 980 - 49 = 931. Очередь = TP + FP = 65 уведомлений. Precision = 16/65 ≈ 24,6%. Требование «recall ⩾ 0,8 и не более 50 уведомлений» не выполнено: полнота подходит, бюджет превышен. Всегда проверяйте оба условия.

Метрики ML: смысл, формулы и расчёт

04 ROC и ROC-AUC

ROC показывает компромисс между найденными срочными и ложными тревогами при разных порогах. **AUC** расшифровывается как «площадь под кривой»; ROC-AUC - площадь именно под ROC. Чем больше, тем лучше ранжирование.

ROC перебирает пороги: **ось X - FPR = FP / (FP + TN)**, **ось Y - TPR = Recall**. Здесь точка (4/90; 8/10) ≈ (0,044; 0,8). Хорошее ранжирование ведёт к левому верхнему углу; диагональ - случайное ранжирование.

ROC-AUC - вероятность, что случайный positive получит score выше случайного negative, с **половиной зачёта за равенство**. **AUC = 0,5 - случайное ранжирование в ожидании; 1 - идеальное.** AUC = 0,8 не означает Accuracy 80%. AUC оценивает ранжирование, а не выбранный порог, калибровку или цену ошибок. При редком классе дополнительно смотрите PR.

Как посчитать руками. Пусть scores по убыванию: [0,9; 0,8; 0,7; 0,1], классы: [срочная A, обычная B, срочная C, обычная D]. Две срочные и две обычные дают 2 × 2 = 4 пары. A выше B и D: 2 зачёта. C выше D, но ниже B: 1 зачёт. **ROC-AUC = (2 + 1) / 4 = 0,75.** При равных scores добавьте 0,5 за пару; делите на число всех пар.

Точки (FPR; TPR): (0; 0) → (0; 0,5) → (0,5; 0,5) → (0,5; 1) → (1; 1). Площадь: 0,5 × 0,5 + 0,5 × 1 = 0,75. Срочная даёт шаг вверх, обычная - вправо. Для ROC нужны оба истинных класса; без одного из них ROC-AUC не определена.

05 Precision-Recall и Average Precision

PR: **X - Recall, Y - Precision**. Показывает, сколько найдено positive и насколько чиста очередь тревог. При редком классе даже маленький FPR может дать много FP из огромного числа negative. Ориентир Precision случайного ранжирования - **prevalence**, доля positive; сравнивать наборы с разными долями нужно осторожно.

AP = Σ (Recall$_i$ − Recall$_{i-1}$) × Precision$_i$. Это сумма precision с весами приростов recall. **AP не равна в общем случае PR-AUC по трапециям**: способ интерполяции различается. В отчёте называйте метод, класс и выборку.

Как посчитать AP руками. В порядке A, B, C, D из примера выше:

Добавили	Recall	Precision
A, срочная	1/2	1/1
B, обычная	1/2	1/2
C, срочная	2/2	2/3
D, обычная	2/2	2/4

Recall растёт на 1/2 при каждой срочной. **AP = 1/2 × 1 + 0 × 1/2 + 1/2 × 2/3 + 0 × 1/2 = 5/6 ≈ 0,833.** При разных scores это среднее precision в моментах нахождения срочных: (1 + 2/3) / 2. Обычные ухудшают precision последующих находок.

Чем выше AP, тем лучше; 1 - идеально, 0,833 не означает «83,3% правильных ответов». Равные scores включайте одной группой и используйте общую формулу с приростом recall; искусственный порядок внутри группы меняет ответ.

Трапеции: площадь участка = ширина по recall × среднее двух precision. С условной начальной точкой (0; 1) в этом примере: 0,5 × (1 + 1)/2 + 0,5 × (1/2 + 2/3)/2 = 19/24 ≈ 0,792. Вертикальные участки имеют нулевую ширину. AP и трапеции дают разные числа из-за способа подсчёта площади.

06 Micro, macro и weighted

Для нескольких классов сначала считайте каждый как «этот класс против остальных».

Усреднение	Как считать	Что важно
Micro	Сложить TP, FP, FN, затем метрику	Больше вес частых классов
Macro	Среднее per-class метрик поровну	Видны редкие классы
Weighted	Среднее с весами support	Support - число истинных объектов класса

Macro-F1 - среднее **F1 классов**, а не F1 от средних P и R. Только при **одной метке на объект и учёте всех классов** micro-P = micro-R = micro-F1 = Accuracy. На multilabel и подмножестве классов это переносить нельзя.

Метрики ML: смысл, формулы и расчёт

07 MAE, MSE и RMSE

Регрессия предсказывает число, например минуты. Обозначения: y_i - факт для заявки i; $\hat{y}_i$ - прогноз; $e_i = \hat{y}_i - y_i$ - ошибка; n - число заявок; Σ - сложить по всем заявкам; abs - модуль (убрать минус); √ - квадратный корень.

Метрика	Формула	Смысл
MAE	$\Sigma \text{ abs}(e_i) / n$	Средний размер промаха, в минутах
MSE	$\Sigma e_i^2 / n$	Средний квадрат ошибки, в минутах²
RMSE	√MSE	Чувствительна к большим промахам, в минутах

Для всех трёх **меньше - лучше; 0 - идеально**. Квадрат усиливает вклад больших ошибок. Знаки сами по себе усреднять нельзя: +2 и -2 дадут 0, хотя обе заявки предсказаны с ошибкой.

Пример по шагам: факт [10, 20, 30], прогноз [12, 18, 40], n = 3.

Факт y	Прогноз ŷ	Ошибка e	abs(e)	e^2
10	12	2	2	4
20	18	-2	2	4
30	40	10	10	100

MAE: складываем модули и делим на 3: (2 + 2 + 10) / 3 = 14/3 ≈ 4,67 мин.

MSE: складываем квадраты и делим на 3: (4 + 4 + 100) / 3 = 108/3 = 36 мин².

RMSE: извлекаем корень из MSE: √36 = 6 мин. Это не квадрат MAE и не среднее корней.

Если один промах вырос с 2 до 20, модуль вырос в 10 раз, квадрат - в 100. Это множители отдельных вкладов, а не всей RMSE. При одинаковых данных и весах RMSE ⩾ MAE. Метрики не различают цену недооценки и переоценки; опасные направления и группы проверяйте отдельно.

08 R^2 и базовый прогноз

R^2 отвечает: насколько модель лучше простого способа «всем предсказывать среднее» по сумме квадратов ошибок? Больше - лучше: 1 - идеально; 0 - как среднее; ниже 0 - хуже среднего. Единиц нет. Это не доля верных прогнозов.

$R^2 = 1 - SSE / SST$. $SSE = \Sigma(y_i - \hat{y}_i)^2$ - сумма квадратов ошибок модели. $SST = \Sigma(y_i - \bar{y})^2$ - сумма квадратов ошибок прогноза средним. Здесь $\bar{y} = \Sigma y_i / n$ - среднее фактических значений.

Шаг 1. Откуда среднее? Факты [10, 20, 30]. Складываем именно их: $\bar{y}$ = (10 + 20 + 30) / 3 = 20. Простой способ всем выдаёт [20, 20, 20].

Шаг 2. С чем сравниваем? Ошибки простого способа: 20 - 10 = 10; 20 - 20 = 0; 20 - 30 = -10. Их квадраты: 100, 0, 100. **SST = 100 + 0 + 100 = 200.**

Шаг 3. Ошибки модели. Для прогноза [12, 18, 40] выше получены квадраты 4, 4, 100. **SSE = 4 + 4 + 100 = 108.** Не делим на n: в формуле сравниваются суммы.

Шаг 4. Подстановка: R^2 = 1 - 108/200 = 0,46. Было 200 у простого способа, стало 108 у модели. Сумма квадратов уменьшилась на (200 - 108)/200 = 46%, а не «46% прогнозов верны».

Как сравнить два прогноза: оставьте факты [10, 20, 30], замените прогноз на [8, 20, 32]. Ошибки [-2, 0, 2]; модули [2, 0, 2]; квадраты [4, 0, 4].

Метрика	[12, 18, 40]	[8, 20, 32]
MAE	14/3 ≈ 4,67	4/3 ≈ 1,33
MSE	108/3 = 36	8/3 ≈ 2,67
RMSE	6	√(8/3) ≈ 1,63
R^2	1 - 108/200 = 0,46	1 - 8/200 = 0,96

Второй прогноз лучше по всем четырём метрикам. **SST осталось 200**, потому что реальные значения не менялись. R^2 разных наборов напрямую не сравнивайте: меняется разброс фактов и знаменатель.

При постоянной цели SST = 0, обычная формула не определена; библиотечная подстановка - отдельное соглашение. Среднее оцениваемых фактов нужно для расчёта R^2. Реальный прогноз для новых заявок строят по train, без знания будущих ответов.

09 Как выбрать метрику

Начните с цели и цены ошибки: ложные тревоги → Precision; пропуски → Recall; баланс → F1; редкие события → PR/AP вместе с числом FP. Ранжирование → ROC-AUC; крупные числовые промахи → RMSE, обычный размер ошибки → MAE. R^2 дополняйте ошибкой в единицах задачи и baseline.

Ответ ментору: тип задачи → positive и ошибки → знаменатель метрики → ограничение → числовой пример. В наборе из 99 обычных и 1 срочной заявки высокий Accuracy ещё не означает пользу. Ошибка 2 → 20 увеличивает вклад в MSE в 100 раз, в MAE - в 10 раз. Модель и порог подбирайте на validation, затем проверяйте на отложенном test без утечки.