# RAG: документы и эмбеддинги

## 01 RAG: путь факта до ответа

**RAG, retrieval-augmented generation**, - генерация с опорой на найденные материалы. Приложение ищет основания, добавляет их к вопросу и передаёт языковой модели. Документы остаются внешним источником: их содержимое не записывается в параметры модели при каждом запросе.

**Индексация** готовит источники заранее: извлечь текст → проверить структуру → разбить на чанки → добавить метаданные → построить поисковые представления. **Обработка вопроса:** определить доступ → найти кандидатов → уточнить порядок → собрать контекст → сгенерировать ответ со ссылками.

**Fine-tuning, дообучение**, меняет параметры модели на примерах. Помогает закрепить формат, стиль и поведение. Для замены правила «30 дней» на «45 дней» обычно обновляют источник и индекс. Дообучение само не обеспечивает удаление отдельного факта, актуальность и разграничение доступа. Эти механизмы можно сочетать.

**Сквозной пример - вымышленный ассистент «Маяка».** Вопрос: «Можно вернуть покупку через 40 дней?» Нужен действующий регламент v2: 45 дней, только для неиспользованного товара. Сравнения 40 ⩽ 45 недостаточно без проверки условия.

**Различайте наблюдения:** источник опубликован; чанк создан; найден на месте 3; вошёл в фактический запрос; правильно пересказан. Найденный документ может исчезнуть при сборке контекста. RAG не гарантирует истину: ошибаются и источники, и поиск, и генератор.

Если оснований нет, ответ должен обозначить ограничение. Вопрос «какой статус заявки сейчас?» может требовать актуального разрешённого чтения системы, а не вчерашнего текстового индекса.

## 02 Чанки: размер и перекрытие

**Чанк** - фрагмент, который ищут и передают отдельно. Маленький точнее локализует совпадение, но теряет условия; большой сохраняет связность, но смешивает темы и расходует контекст. Универсального размера нет: сравнивают на своих вопросах.

**Токен** - единица выбранного токенизатора; это не обязательно слово или символ. **Overlap, перекрытие**, повторяет часть текста на стыках. При размере 200 и overlap 40 шаг равен 200 − 40 = 160 токенов.

**Считаем документ из 500 токенов.** Первое окно: 1-200, длина 200. Второе: 161-360, длина 200. Третье: 321-500, длина 180.

Суммарно сохраняем 200 + 200 + 180 = **580 токенов**. Две зоны по 40 повторены: 580 − 500 = 80 дополнительных токенов. Три чанка одного правила не становятся тремя независимыми подтверждениями.

Делите по заголовкам, абзацам и смысловым блокам. Строке таблицы нужны названия колонок; условию - правило, которое оно ограничивает. Путь заголовков «Возвраты → Сроки → Исключения» помогает понять короткий фрагмент. Идентификатор ERR-4031 сохраняют точно: ERR-403 - другой объект.

**Проверка границы:** фраза «45 дней» на одной карточке, «только неиспользованный товар» на другой. Найденная первая карточка ещё не даёт полного основания. Проверьте совместную доставку, а не только наличие обоих чанков в индексе.

Overlap не исправляет потерянную колонку при извлечении PDF. Лимит модели эмбеддингов и окно генератора могут различаться; измеряйте объём нужным токенизатором.

## 03 Эмбеддинги и метаданные

**Эмбеддинг** - список чисел фиксированной длины, построенный моделью для текста. **Размерность** - число координат: (0,2; −0,4; 0,7) имеет три. Семантический поиск может сблизить «деньги назад» и «возврат оплаты» без одинаковых слов.

Близость не доказывает согласие: «возврат разрешён» и «возврат запрещён» относятся к одной теме. Отдельная координата обычно не означает конкретное человеческое понятие. Учебные двумерные примеры ниже объясняют геометрию, а не настоящие значения текстовой модели.

**Совместимое пространство** требует согласованной модели, версии, подготовки текста, режимов запроса/документа и нормализации. Одинаковая размерность двух моделей разрешает арифметику, но не делает их координаты общей картой. Префиксы query: и passage: нужны только там, где их предусматривает выбранная модель.

**Миграция:** подготовить новый индекс → перекодировать документы → сравнить поиск на фиксированных вопросах → согласованно переключить индекс и кодировщик запросов. Не смешивать старые и новые векторы. Изменился текст чанка - его старый вектор уже описывает другой текст.

**Метаданные** связывают число с источником: chunk_id - ID фрагмента; document_id - стабильный ID документа; version - редакция; раздел - место; статус и дата действия - применимость; область доступа - кто вправе читать.

source_updated_at означает изменение источника; indexed_at - построение записи; valid_from - начало действия правила. Свежая индексация архивной v1 не делает её актуальной. Ссылка в ответе должна вести к нужной версии и месту, а не просто к похожему документу.

# RAG: документы и эмбеддинги

## 04 Dot product и расстояние L2

Пусть **q = (1,0)** - вопрос, **a = (2,0)** и **b = (1,1)** - два фрагмента. Координаты здесь условные. **Dot product, скалярное произведение**, умножает координаты на одинаковых местах и складывает результаты.

**q·a = 1×2 + 0×0 = 2.** Точка между буквами обозначает скалярное произведение.

**q·b = 1×1 + 0×1 = 1.** Если поиск настроен на dot product, больше - ближе; a выше b. На результат влияют направление и длина вектора.

**L2** - евклидово расстояние, длина прямого отрезка между точками. Вычитаем одноимённые координаты, возводим каждую разность в квадрат, складываем и извлекаем корень. Знак √ означает квадратный корень.

**L2(q,a) = √((1−2)² + (0−0)²) = √1 = 1.**

**L2(q,b) = √((1−1)² + (0−1)²) = √1 = 1.**

Здесь ничья: для расстояния меньше - ближе. Dot и L2 дали разные результаты при тех же объектах. Некоторые системы возвращают квадрат L2 без корня: порядок сохраняется, числовой порог меняется.

**Изменим только длину:** вместо a возьмём (20,0). Dot станет 1×20 + 0×0 = 20. L2 станет √((1−20)² + 0²) = 19. Вектор направлен так же, но гораздо дальше от q как точка.

Рост dot с 2 до 20 не доказывает улучшение ответа. Мы изменили геометрию учебного вектора, а не проверили содержание документа. Название поля score не говорит, какая мера возвращена: сначала выясните формулу и направление сравнения.

## 05 Косинус и нормализация

**Норма norm(v)** - длина вектора v: корень из суммы квадратов координат. Для q=(1,0), a=(2,0), b=(1,1): norm(q)=√(1²+0²)=1; norm(a)=√(2²+0²)=2; norm(b)=√(1²+1²)=√2≈1,414.

**Косинусное сходство cos(q,a) = (q·a) / (norm(q) × norm(a)).** Делим скалярное произведение на произведение длин, чтобы сравнить направления без влияния масштаба.

Для a: cos(q,a) = 2 / (1×2) = **1**.

Для b: cos(q,b) = 1 / (1×√2) ≈ **0,707**.

У ненулевых векторов cosine лежит от −1 до 1; больше - ближе направление. Для a=(20,0) получаем 20/(1×20)=1: длина выросла, направление осталось прежним. Если система возвращает 1−cos, это расстояние, и меньше - лучше.

**Нормализация** делит каждую координату на длину. a превращается в (1,0), b - в (1/√2,1/√2). Теперь длины равны 1: сравниваем направления, устранив преимущество масштаба.

У единичных векторов dot равен cosine; **L2² = 2 − 2×cos**. Для нормализованных q и b: L2²≈2−1,414=0,586; L2≈0,765. Ранжирование совпадает, хотя числа и направление «лучше» различаются. Без единичных длин это обещание неверно.

Нулевой вектор имеет длину 0: cosine и нормализация не определены. Проверьте пустой ввод и выход кодировщика, явно обработайте сбой.

**Cosine 0,8 не означает 80% вероятности правильного ответа.** Это геометрический score. Порог полезности проверяют по разметке; после смены модели прежнее число может потерять смысл.

## 06 Свежесть и потерянное условие

**Публикация версии:** сначала подготовить и проверить новые чанки, затем согласованно включить v2 и исключить v1 из обычного текущего поиска. Удалить v1 раньше - получить окно без ответа; оставить обе активными - смешать правила 30 и 45 дней.

Максимальная дата не определяет действующий документ: более новый файл может быть черновиком. Историческому вопросу нужна редакция на указанную дату, если такая функция поддерживается и доступ разрешён. Удаление источника должно исключить его чанки и применимые кэши, а не только исходный файл.

**Ответ остался «30 дней».** Проверьте опубликованную v2 → активные чанки → фильтр версии и доступа → кандидатов → фактический контекст → утверждение ответа. Сегодняшний indexed_at у v1 подтверждает только время обработки. Если v2 отсутствует, увеличение числа результатов не создаст её.

**Ответ разрешает использованный товар.** Найдите условие «только неиспользованный» в исходнике. Если его потеряли при извлечении - исправьте извлечение. Отделили при чанкинге - пересмотрите границы. Есть в кандидате, нет в контексте - проверьте отбор и бюджет. Дошло до модели, но ответ противоречит - проверяйте генерацию.

**После смены кодировщика выдача случайная.** Сравните версии моделей, префиксы и нормализацию документов и вопросов. Совпавшая размерность не исключает несовместимость; ошибка может не вызвать исключения программы.

Меняйте один подтверждённый участок и повторяйте те же вопросы. Для трассы обычно достаточно ID, версий и рангов: полный внутренний текст не нужен в обычном логе. Права задаёт доверенный сервер; нельзя исправлять полноту раскрытием запрещённых материалов.